artigos de revisão

Doi:10.1145/2133806.2133826

Levantamento de um conjunto de algoritmos que oferecem uma solução para o gerenciamento de grandes arquivos de documentos.

Por DaviD m. Blei

Modelos temáticos probabilísticos

Como o conhecimento OUr COLLeCTive continua a ser digitalizado e armazenado - na forma de notícias, blogs, páginas da Web, artigos científicos, livros, imagens, som, vídeo e redes sociais - torna-se mais difícil encontrar e descobrir o que estamos procurando. Precisamos de novas ferramentas computacionais para ajudar a organizar, pesquisar e compreender estas vastas quantidades de informação.

Neste momento, trabalhamos com informações on-line usando duas ferramentas principais - pesquisa e links. Digitamos palavras-chave em um mecanismo de busca e encontramos um conjunto de documentos relacionados a elas. Procuramos os documentos desse conjunto, possivelmente navegando para outros documentos vinculados. Esta é uma maneira poderosa de interagir com nosso arquivo on-line, mas algo está faltando.

Imagine pesquisar e explorar documentos com base nos temas que os atravessam. Podemos "ampliar" e "diminuir" para encontrar temas específicos ou mais amplos; podemos observar como esses temas mudaram com o tempo ou como eles estão conectados entre si. Em vez de encontrar documentos

apenas através da busca por palavras-chave, podemos primeiro encontrar o tema que nós estão interessados, e depois examinam os documentos relacionados a esse tema.

Por exemplo, considere o uso de temas para explorar a história completa do New York Times. Em um nível amplo, alguns dos temas podem corresponder às seções do jornal por assinatura, assuntos nacionais, esportes. Poderíamos ampliar um tema de in- terest, como a política externa, para revelar vários aspectos da mesma - a política externa chinesa, o conflito no Oriente Médio, o relacionamento dos EUA com a Rússia. Poderíamos então navegar no tempo para revelar como estes temas específicos mudaram, acompanhando, por exemplo, as mudanças no conflito no Oriente Médio nos últimos 50 anos. E, em toda esta exploração, seríamos apontados para os artigos originais relevantes para os temas. A estrutura temática seria um novo tipo de janela através da qual se poderia explorar e digerir a coleção.

Mas não interagimos com os arquivos elec- tronic desta forma. Enquanto mais e mais textos estão disponíveis on-line, simplesmente não temos o poder humano de lê-los e estudá-los para proporcionar o tipo de experiência de navegação descrita acima. Para este fim, pesquisadores de aprendizado de máquina desenvolveram *a modelagem probabilis- tic*, um conjunto de algoritmos que visam descobrir e anotar grandes arquivos de documentos com informações temáticas. A modelagem tópica de algo- rithms são métodos estatísticos que ana- lyze as palavras dos textos originais para descobrir os temas que os atravessam, como esses temas estão conectados entre si e como eles mudam

» principais percepções

- **Os modelos temáticos são algoritmos para descobrir os principais temas que permeiam uma grande coleção de documentos e, de outra forma, não estruturada. Os modelos temáticos podem organizar a coleção de acordo com os temas descobertos.**
- **algoritmos de modelagem temática podem ser aplicados a coleções maciças de documentos.**
  Os recentes avanços neste campo nos permitem analisar coleções de streaming, como você pode encontrar em um Web aPi.
- **Entre outras aplicações, eles têm sido usados para encontrar padrões em dados genéticos, imagens e redes sociais.**

tempo. (Veja, por exemplo, a Figura 3 para os tópicos encontrados através da análise do *Yale Law Journal*). Os algoritmos de modelagem de tópicos não exigem nenhuma anotação prévia ou etiquetagem dos documentos - os tópicos emergem da análise dos textos origi- nal. A modelagem de tópicos nos permite organizar e resumir arquivos eletrônicos em uma escala que seria impossivel - por meio de anotações humanas.

alocação de Dirichlet latente

Primeiro descrevemos as idéias básicas por trás da *alocação Dirichlet latente* (LDA), que é o modelo temático mais simples. [8] A intuição por trás da LDA é que os documentos exibem múltiplos tópicos. Por exemplo, considere o artigo da Figura 1. Este artigo, intitulado "Buscando as Necessidades (Genéticas) da Vida", trata do uso da análise de dados para determinar o número de genes que um organismo precisa para sobreviver (em um sentido evolucionário).

À mão, destacamos palavras diferentes que são usadas no artigo. Palavras sobre *análise de dados*, tais como "computador" e "previsão", são destacadas em azul; palavras sobre *biologia evolutiva*, tais como "vida" e "organismo", são destacadas em rosa; palavras sobre *genética,* tais como "sequenciado" e "genes", são destacados em amarelo. Se demorássemos um tempo para destacar cada palavra no artigo, você veria que este arti- clemente mistura genética, análise de dados e biologia evolutiva em diferentes porções pró-. (Excluímos palavras, como "e" "mas" ou "se", que contêm pouco conteúdo tópico). Além disso, saber que este artigo mistura esses tópicos ajudaria a situá-lo em uma coleção de artigos científicos.

O LDA é um modelo estatístico de coleções docu- ment que tenta captar esta intuição. Ela é descrita mais facilmente por seu processo generativo, o processo imaginário aleatório pelo qual o modelo assume que os documentos surgiram. (A interpretação do LDA como um modelo probabilístico é explicada posteriormente).

Definimos formalmente um *tópico* para ser uma distribuição sobre um vocabulário fixo. Por exemplo, o tópico de *genética* tem palavras sobre genética com alta probabilidade e o tópico de *biologia evolutiva* tem palavras sobre biologia evolutiva com alta probabilidade. Assumimos que estes tópicos são especificados antes de qualquer dado ter sido gerado.[a] Agora, para cada documento na coleção, nós geramos - comemos as palavras em um processo de duas etapas.

. Escolha aleatoriamente uma distribuição por tópicos.

. Para cada palavra do documento

a. Escolha aleatoriamente um tópico da distribuição em vez de tópicos na etapa nº 1.

b. Escolha aleatoriamente uma palavra da distribuição correspondente sobre o vocabulário.

Este modelo estatístico reflete a intuição de que os documentos exibem tópicos com várias pontas. Cada documento exibe - seus tópicos em proporção diferente (passo #1); cada palavra em cada documento é extraída de um dos tópicos (passo #2b), onde o tópico selecionado é escolhido a partir da distri- buição por-documento sobre os tópicos (passo #2a). [b]

No artigo de exemplo, a distribuição sobre tópicos colocaria a capacidade de sondagem em *genética*, *análise de dados*, e

a Tecnicamente, o modelo pressupõe que os ics superiores são gerados primeiro, antes dos documentos.

b Devemos explicar o nome misterioso, "alocação Dirichlet latente". A distribuição que é usada para desenhar a distribuição temática por-documento no passo 1 (o histograma dos desenhos animados na Figura 1) é chamada de *distribuição Dirichlet*. No processo genera- tive para LDA, o resultado do Dirichlet é usado para *alocar* as palavras do documento para diferentes tópicos. Por que *latente*? Continue lendo.

dad 0.02
os
número 0.02
computa 0.01
dor

art
rev

figura 1. as intuições por trás da alocação de Dirichlet latente. Assumimos que existe algum número de "tópicos", que são distribuições por palavras, para toda a coleção (extrema esquerda). cada documento é assumido como segue. primeiro escolha uma distribuição sobre os tópicos (o histograma à direita); depois, para cada palavra, escolha uma atribuição de tópico (as moedas coloridas) e escolha a palavra do tópico correspondente. os tópicos e atribuições de tópico nesta figura são ilustrativos - eles não se encaixam em dados reais. Veja a figura 2 para os tópicos que cabem a partir dos dados.

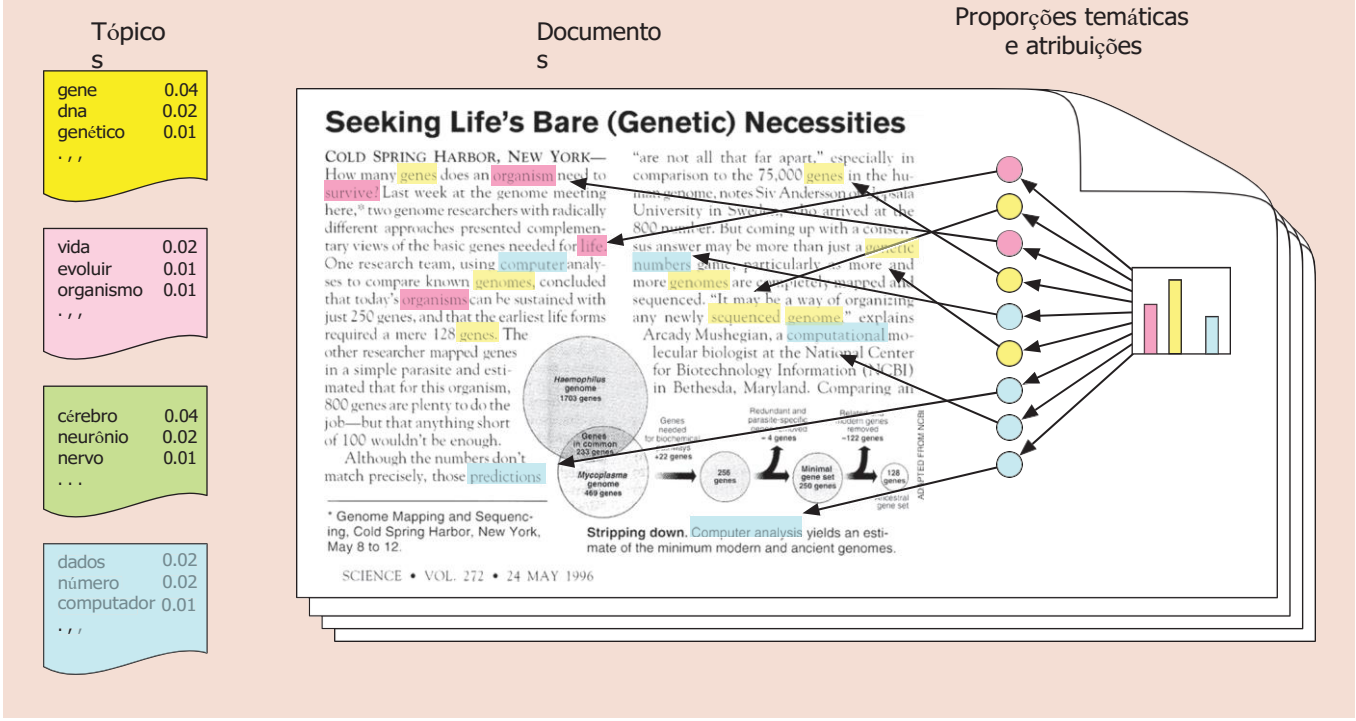

figura 2. Inferência real com LDA. Nós ajustamos um modelo 100-topic LDA a 17.000 artigos da revista *Science*. à esquerda estão as proporções dos tópicos inferidos para o artigo de exemplo da figura 1. à direita estão as 15 palavras mais freqüentes dos tópicos mais freqüentes encontrados neste artigo.

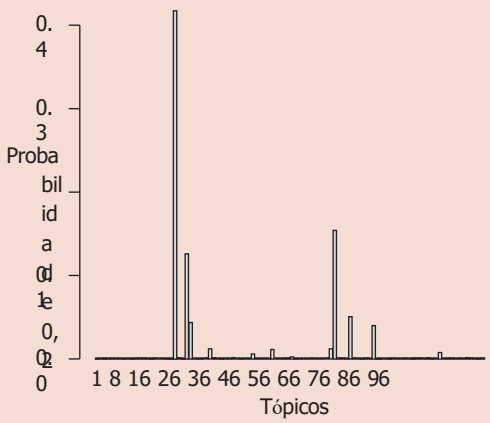

"Genética"
do DNA do genoma humano seqüenciamento de genes genéticos seqüenciamento molecular de genes mapeamento de informações genéticas seqüências de projetos de mapeamento

"Evolução"
evolução da vida dos organismos das espécies evolucionárias grupos de biologia de origem grupo de diversidade filogenética viva novos dois comuns

"Doença"
doença hospedeira de bactérias resistência bacteriana novas cepas controlam parasitas infecciosos da malária unidos tuberculose

Modelos de computador
"Computadores"
modelos de sistemas de rede de computadores de dados de informação métodos paralelos redes de software novas simulações

biologia evolutiva, e cada palavra é extraída de um desses três top- ics. Observe que o próximo artigo da coleção poderia ser sobre *análise de dados* e *neurociência*; sua distribuição sobre tópicos colocaria a capacidade de sondagem sobre esses dois tópicos. Esta é a característica distintiva da alocação Dirichlet latente - todos os documentos da coleção compartilham o mesmo conjunto de tópicos, mas cada docu- mento exibe esses tópicos em proporção diferente.

Como descrevemos na introdução, o objetivo da modelagem de tópicos é descobrir automaticamente os tópicos a partir de uma coleção de documentos. Os documentos em si são observados, enquanto a estrutura dos tópicos - os tópicos, a distribuição dos tópicos por-documento e a atribuição dos tópicos por palavra - é uma *estrutura oculta*. O problema computacional central para a modelagem de tópicos é usar os documentos observados para inferir a estrutura de tópicos ocultos. Isto pode ser pensado como "revertendo" o processo generativo - qual é a estrutura oculta que provavelmente gerou a coleção observada?

A figura 2 ilustra o exemplo inference usando o mesmo exemplo document da figura 1. Aqui, pegamos 17.000 artigos da revista *Science* e usamos um algoritmo de modelagem de tópicos para inferir a estrutura de tópicos ocultos. (O algoritmo assumiu que existiam 100 tópicos). Calculamos então a distribuição de tópicos inferidos para o artigo de exemplo (Figura 2, esquerda), a distribuição por tópicos que melhor descreve sua coleção par- ticular de palavras. Note que esta distribuição por tópicos, embora possa usar qualquer um dos tópicos, tem apenas "activated" um punhado deles. Além disso, podemos examinar os termos mais prováveis de cada um dos tópicos mais prováveis (Figura 2, à direita). Ao examinar, vemos que estes termos são reconhecíveis como termos sobre genética, sobrevivência e análise de dados, os tópicos que são comcitados no artigo de exemplo.

Ressaltamos que os algoritmos não têm informações sobre estes subtemas e os artigos não são etiquetados com tópicos ou palavras-chave. As distribuições de tópicos entre tabelas surgem através da computação da estrutura oculta que provavelmente gerou a leitura col- letiva observada dos documentos.[c] Por exemplo, a Figura 3 ilustra os tópicos descobertos no *Yale Law Journal*. (Aqui o num- ber de tópicos foi definido para ser 20.) Tópicos

c De fato, chamar esses modelos de "modelos tópicos" é retrospectivo - os tópicos que emergem do

algoritmo de inferência são interpretáveis para quase todas as coleções que são analisadas. O fato de que estes parecem ser tópicos tem a ver com a estrutura estatística da linguagem observada e como ela interage com as suposições probabilísticas específicas da LDA.

sobre temas como genética e análise de dados são substituídos por temas sobre discriminação e direito contratual.

A utilidade dos modelos temáticos deriva da propriedade que a estrutura escondida inferida se assemelha à estrutura temática da coleção. Esta estrutura oculta inter- modelo anotará cada documento da coleção - uma tarefa que é delicada de executar à mão - e estas anotações podem ser usadas para auxiliar tarefas como recuperação de informações, classificação e exploração de corpus. [d] Desta forma, o modelo temático fornece uma solução algorítmica para gerenciar, organizar e anotar grandes arquivos de textos.

Lda e modelos probabilísticos. LDA e outros modelos tópicos fazem parte do campo maior da *modelagem probabilística*. Na modelagem probabilística generativa, tratamos nossos dados como sendo decorrentes de um processo generativo que inclui *variáveis escondidas*. Este processo generativo define uma *distribuição conjunta de probabilidade* sobre as variáveis aleatórias observadas e ocultas. Realizamos a análise de dados usando essa distribuição conjunta para calcular a *distri- buição condicional* das variáveis ocultas, dada a

d Veja, por exemplo, o navegador da *Wikipedia* construído com um modelo de tópico em http://www.sccs.swarthmore.edu/users/08/ajb/tmve/wiki100k/ browse/topic-list.html.

figura 3. um modelo de tópico adequado ao *Yale Law Journal*. aqui, há 20 tópicos (os oito primeiros são traçados). cada tópico é ilustrado com suas palavras mais freqüentes. a posição de cada palavra ao longo do *eixo x* denota sua especificidade para os documentos. por exemplo, "patrimônio" no primeiro tópico é mais específico do que "imposto".

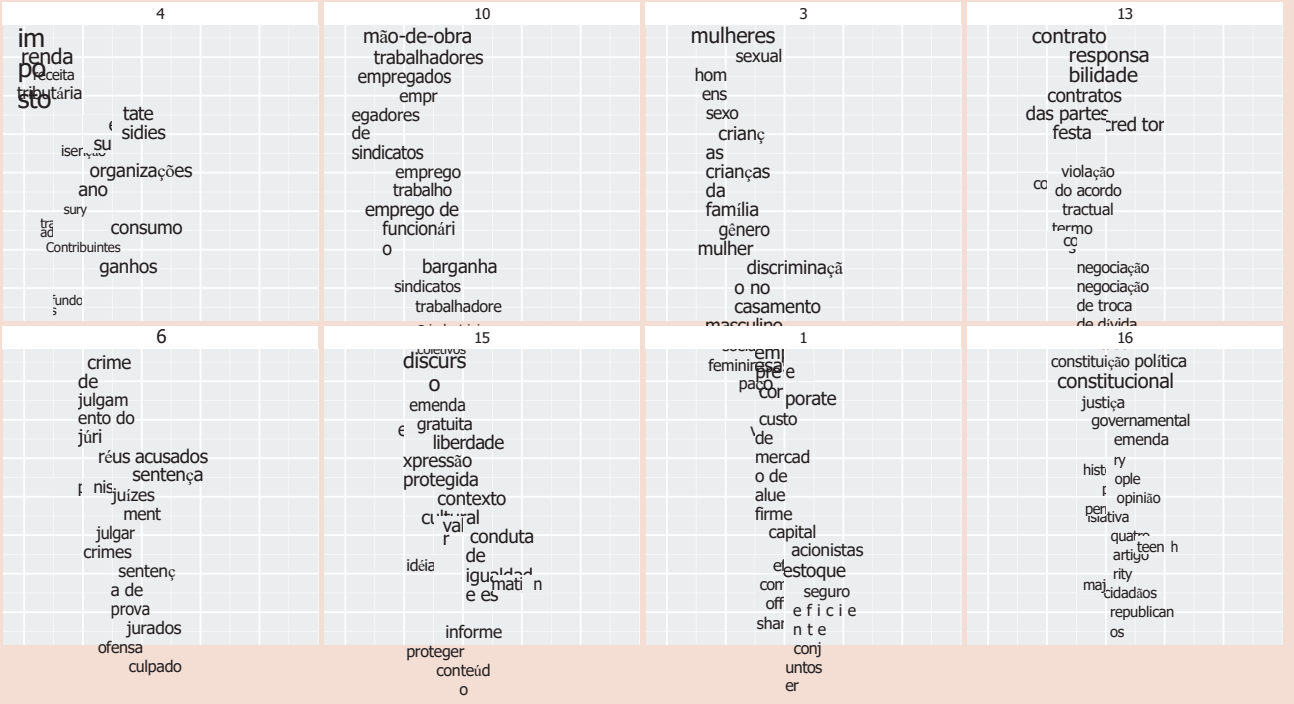

variáveis observadas. Esta distribuição condicional também é chamada de *distribuição posterior*.

A LDA se enquadra precisamente neste trabalho de enquadramento. As variáveis observadas são as palavras dos documentos; as variáveis ocultas são a estrutura temática; e o processo gerativo é como descrito aqui. O problema computacional de inferir a estrutura temática oculta dos documentos é o problema de calcular a distribuição posterior, a distribuição condicional das variáveis escondidas dos documentos.

Podemos descrever a LDA mais formalmente com a seguinte notação. Os tópicos são $b_{1:K}$, onde cada b_k é uma distribuição sobre o vocabulário (as distribuições sobre as palavras à esquerda na Figura 1). As proporções do tópico para o documento *dth* são q_d , onde $q_{d,k}$ é a proporção do tópico para o tópico *k* no documento *d* (o histograma do toon do carro na Figura 1). As proporções de tópicos para o documento *dth* são z_d , onde $z_{d,n}$ é a proporção de tópicos para a *n-ésima* palavra no documento *d* (a moeda colorida na Figura 1). Finalmente, as palavras observadas para o documento *d* são w_d ,

Com esta notação, o processo generativo para LDA corresponde à distribuição das variáveis ocultas e observadas em conjunto,

$$p(\beta_{1:K}, \theta_{1:D}, z_{1:D}, w_{1:D}) = \prod_{i=1}^{K} p(\beta_i) \prod_{d=1}^{D} p(\theta_d) \left(\prod_{n=1}^{N} p(z_{d,n} | \theta_d) p(w_{d,n} | \beta_{1:K}, z_{d,n}) \right). \quad (1)$$

Observe que esta distribuição especifica uma série de dependências. Por exemplo, a atribuição do tópico $z_{d,n}$ depende das proporções por-documento do tópico q_d . Como outro exemplo, a palavra observada $wd_{,n}$ depende do tópico assign- ment $zd_{,n}$ e de *todos* os tópicos $b1_{:K.}$ (Operacionalmente, esse termo é definido pela pesquisa de qual tópico $zd_{,n}$ se refere e pela pesquisa da probabilidade da palavra $wd_{,n}$ dentro desse tópico).

Estas dependências definem a LDA. Elas são codificadas nas suposições estatísticas por trás do processo generativo, na forma matemática particular da distribuição conjunta, e...

linguagem para descrever famílias de distribuições de probabilidade. [e] O modelo gráfico de cal para LDA está na Figura 4. Estas três representações são formas equivalentes de descrever as suposições probabilísticas por trás da LDA.

Na próxima seção, descrevemos os algoritmos de inferência para LDA. Entretanto, primeiro fazemos uma pausa para descrever a curta história destas idéias. O LDA foi desenvolvido para corrigir um problema com um modelo *probabilístico* de *análise semântica latente* (pLSI) desenvolvido previamente. [21] Esse modelo era em si uma versão probabilística do trabalho seminal sobre *análise semântica latente*,[14] que revelou a utilidade da decomposição do valor singular da matriz documentária-terminal. Desta perspectiva de fatorização da matriz, a LDA também pode ser vista como um tipo de análise de componentes principais para dados discretos. [11, 12]

Computação posterior para a Lda. Passamos agora para o cálculo computacional

e O campo dos modelos gráficos é na verdade mais do que uma linguagem para descrever

famílias de distribuições. É um
onde $w_{d,n}$ é a *enésima* palavra no documento
d, que é um elemento do vocabulário fixo.

campo que ilumina o
de uma terceira maneira - na *probabilística*
modelo gráfico para LDA. Os modelos gráficos probabilísticos fornecem um modelo gráfico

ligações matemáticas profundas entre probabi- independência lística, teoria gráfica, e algo...

rithms para computação com distri- buições de probabilidade. [35]

problema, calculando a distribuição condicional da estrutura temática dada os documentos observados. (Como mencionamos, isto é chamado de *posterior*.) Usando nossa notação, o posterior é

$$p(\beta_{1:K}, \theta_{1:D}, z_{1:D} \mid w_{1:D}) = \frac{p(\beta_{1:K}, \theta_{1:D}, z_{1:D}, w_{1:D})}{p(w_{1:D})}. \quad (2)$$

O numerador é a distribuição conjunta de todas as variáveis aleatórias, que pode ser facilmente computada para qualquer configuração das variáveis ocultas. O denomina- tor é a *probabilidade marginal* das observações, que é a probabilidade de ver o corpus observado sob qualquer modelo tópico. Em teoria, ele pode ser computado pela soma da distri- buição conjunta sobre cada instante possível da estrutura do tópico oculto.

Esse número de estruturas temáticas possíveis, entretanto, é exponencialmente grande; essa soma é intratável para com- pute. [f] Quanto a muitos probabilis modernos - modelos de interesse - e para grande parte das estatísticas Bayesianas modernas - não podemos computar o posterior por causa do denominador, que é conhecido como a *evidência*. Um objetivo central de pesquisa do modelo probabilístico moderno é desenvolver métodos eficientes para aproximá-lo. Algoritmos de modelagem tópica - como os algoritmos usados para criar as Figuras 1 e 3 - são muitas vezes adaptações de metáforas de uso geral - ods para a aproximação da distribuição posterior.

Os algoritmos de modelagem temática formam uma aproximação da Equação 2, adaptando uma distribuição alternativa sobre a estrutura temática latente para se aproximar do verdadeiro posterior. Os algoritmos de modelagem de tópicos geralmente se enquadram em duas categorias - algo- rithms baseados em amostragem e algoritmos variacionais.

Baseado na amostragem Os algoritmos tentam coletar amostras do posterior para aproximá-lo com uma distribuição empírica. O algoritmo de amostragem mais utilizado para modelagem de tópicos é o *Gibbs* A distribuição limitadora é a posterior. A cadeia de Markov é definida nas variáveis temáticas ocultas para um determinado corpus, e o algoritmo é executar a cadeia por um longo período de tempo, coletar amostras da distribuição limitada, e depois aproximar a distribuição com as amostras coletadas. (Muitas vezes, apenas uma amostra é coletada como uma aproxi- mação da estrutura do tópico com

figura 4. o modelo gráfico para alocação de Dirichlet latente. cada nó é uma variável aleatória e é rotulada de acordo com seu papel no processo generativo (ver figura 1). os nós ocultos - as proporções do tópico, atribuições e tópicos - não estão sombreados. os nós observados - as palavras dos documentos - estão sombreadas. os retângulos são notações de "placa", o que denota replicação. a placa denota as palavras da coleção dentro dos documentos; a placa *D* denota a coleção de documentos dentro da coleção.

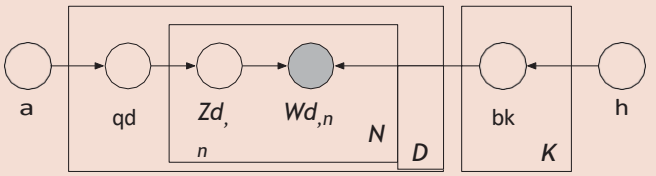

figura 5. dois tópicos de um modelo temático dinâmico. este modelo foi adequado à *Ciência* de 1880 a 2002. Temos ilustrado as principais palavras a cada década.

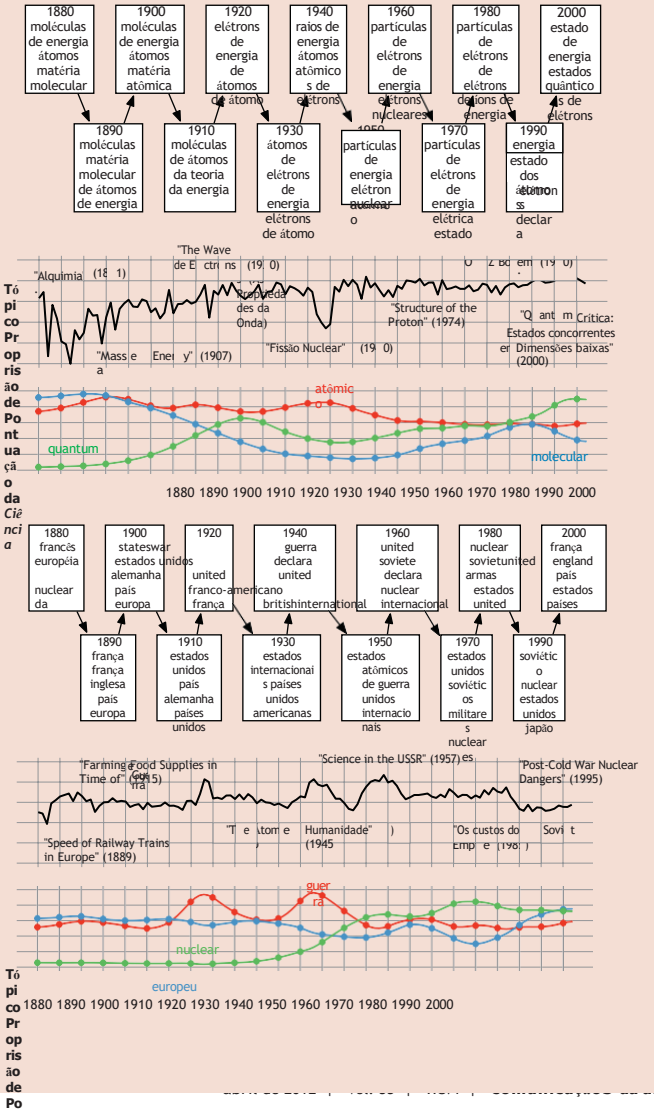

amplitude onde construímos uma *cadeia de Markov* - uma seqüência de variáveis aleatórias, cada uma dependente da anterior - que

f Mais tecnicamente, a soma está sobre todas as formas possíveis de atribuir cada palavra observada da coleção a um dos tópicos. As legendas dos documentos contêm geralmente palavras observadas, pelo menos na ordem de milhões.

probabilidade máxima). Veja Steyvers e Griffiths33 para uma boa descrição da amostragem Gibbs para LDA, e veja http:// CRAN.R-project.org/package=lda para uma rápida implementação de código aberto.

Os métodos variáveis são uma alternativa minística de dissuasão aos algoritmos baseados em amostragem. [22,35] Em vez de aproximadamente acoplar o posterior com as amostras, os métodos variacionais representam uma família parametrizada de distribuições sobre a estrutura oculta e depois encontrar o membro dessa família que está mais próximo do posterior. [g] Assim, o problema de inferência é transformado em um problema de opti- mização. As metáforas variáveis abrem a porta para inovações em otimização para ter impacto prático na modelagem probabilística. Veja Blei et al. [8] para um algoritmo de inferência de variatação coordenada para LDA; veja Hoffman et al. [20] para um algoritmo online muito mais rápido (e software de código aberto) que lida facilmente com milhões de documentos e pode acomodar coleções de texto em fluxo contínuo.

Falando vagamente, ambos os tipos de algoritmos realizam uma pesquisa sobre a estrutura do tópico. Uma coleção de docu- mentos (as variáveis aleatórias observadas no modelo) são mantidas fixas e servem como um guia para onde pesquisar. Qual abordagem é melhor dependendo do modelo temático específico que está sendo usado - até agora nos concentramos na LDA, mas veja abaixo para outros modelos temáticos - e é uma fonte de debate acadêmico. Para uma boa discussão sobre os méritos e desvantagens de ambos, ver Asuncion et al. [1]

Pesquisa em modelagem de tópicos

O modelo simples da LDA fornece uma ferramenta errática para descobrir e explorar a estrutura temática oculta em grandes arquivos de texto. Entretanto, uma das principais vantagens de formular o LDA como um modelo probabilístico é que ele pode ser facilmente usado como um módulo em modelos mais complicados para objetivos mais complicados. Desde sua introdução, o LDA foi ampliado e adaptado de várias maneiras.

relaxando as suposições da Lda. A LDA é definida pelas suposições estatísticas que faz sobre a

uma direção para a modelagem de tópicos é desenvolver métodos de avaliação que combinam como os algoritmos são utilizados. como podemos comparar modelos temáticos com base na sua interpretação?

corpus. Uma área ativa de pesquisa de modelos de tópicos é como relaxar e estender estas suposições para descobrir uma estrutura mais sofisticada nos textos.

Uma suposição que a LDA faz é a suposição do "saco de palavras", que a ordem das palavras no documento não importa. (Para ver isto, observe que a distribuição conjunta da Equação 1 permanece invariável à permutação das palavras dos documentos). Embora esta suposição seja irrealista, ela é re - sonível se nosso único objetivo for descobrir a estrutura semântica do curso dos textos. [h] Para objetivos mais sofisticados - como a geração de linguagem - ela não é evidentemente apropriada. Tem havido uma série de extensões da LDA que modelam as palavras de forma inalterável. Por exemplo, Wallach36 desenvolveu um modelo de tópico que relaxa a suposição de palavras, assumindo que os tópicos geram palavras condicionadas à palavra anterior; Griffiths et al. [18] desenvolveram um modelo de tópico que alterna entre LDA e um HMM padrão. Estes modelos ampliam significativamente o espaço de parâmetros, mas mostram um melhor desempenho na modelagem da linguagem.

Outra suposição é que a ordem dos documentos não importa. Novamente, isto pode ser visto notando-se que a Equação 1 permanece invariável às permutações da ordenação de documentos na coleção. Esta suposição pode ser irrealista ao se analisar coleções de longa duração que se estendem por anos ou séculos. Em tais coleções, podemos querer assumir que os *tópicos* mudam com o tempo. Uma abordagem para este problema é o modelo temático dinâmico5 - um modelo que respeita a ordenação dos documentos - e dá uma estrutura tópica posterior mais rica do que a LDA. A Figura 5 mostra um tópico que resulta da análise de toda a revista *Science* sob o modelo de tópicos dinâmicos. Em vez de uma única distribuição por palavras, um tópico é agora uma seqüência de distribuições por palavras. Podemos encontrar um tema subjacente da coleção e acompanhar como ele mudou ao longo do tempo.

Uma terceira suposição sobre a LDA é que o número de tópicos é assumido

g A proximidade é medida com a *divergência Kullback-Leibler*, uma medida teórica da informação - medida da distância entre duas distribuições de probabilidade.

h Como uma experiência de pensamento, imagine embaralhar as palavras do artigo da Figura 1. Mesmo quando baralhado, você seria capaz de perceber que o artigo tem algo a ver com genética.

conhecido e fixo. O modelo de tópicos não paramétricos Bayesianos34 fornece uma solução elegante: o número de tópicos é determinado pela coleção durante a inferência posterior e, além disso, novos documentos podem exibir tópicos nunca antes vistos. Os modelos Bayesianos de tópicos não paramétricos foram estendidos para hierarquias de tópicos, que encontram uma árvore de tópicos, passando de mais gerais para mais concretos, cuja estrutura particular é inferida a partir dos dados. [3]

Há ainda outras extensões da LDA que relaxam várias suposições feitas pelo modelo. O modelo de tópicos correlatos6 e a máquina de alocação pachinko24 permitem a ocorrência de tópicos para exibir correlação (por exemplo, um documento sobre *geologia* é mais provável que seja também sobre *química* do que sobre *esportes*); o modelo de tópicos esféricos28 permite que palavras sejam *improváveis* em um tópico (por exemplo, "chave inglesa" será particularmente improvável em um tópico sobre *gatos*); modelos de tópicos esparsos reforçam a estrutura nas distribuições de tópicos; [37] e modelos de tópicos "estourados" fornecem um modelo mais realista de contagem de palavras. [15]

incorporando metadados. Em muitas configurações de análise de texto, os documentos contêm informações adicionais - tais como autor, título, localização geográfica, links e outros - que podemos querer levar em conta ao adequar um modelo tópico. Tem havido uma enxurrada de pesquisas sobre a adaptação de modelos de tópicos para incluir metadados.

O modelo autor-tópico29 é uma história de sucesso inicial para este tipo de pesquisa. As proporções do tópico são anexadas aos autores; trabalhos com múltiplos autores são assumidos para anexar cada palavra a um autor, extraída de um tópico extraído de suas proporções do tópico. O modelo autor-tópico permite inferências sobre autores, assim como docu- mentos. Rosen-Zvi et al. mostram exemplos de similaridade de autor com base em suas proporções do tópico - tais cálculos não são possíveis com LDA.

Muitas coleções de documentos estão vinculadas - por exemplo, artigos científicos estão vinculados por citação ou páginas da Web estão vinculadas por hiperlinks - e vários modelos de tópicos foram desenvolvidos para dar conta desses links ao estimar o top- ics. O *modelo temático relacional* de Chang e Blei[13] assume que cada documento é modelado como na LDA e que os links entre documentos depende da des- tância entre suas proporções temáticas. Este é tanto um novo modelo temático quanto um novo modelo de rede. Ao contrário dos modelos estatísticos tradicionais de redes, o modelo temático rela- tional leva em conta os atributos dos nós (aqui, as palavras dos documentos) na modelagem dos links.

Outros trabalhos que incorporam metadados em modelos tópicos incluem mod- els de estrutura linguística,[10] modelos que contabilizam as distâncias entre corpora,[38] e modelos de entidades nomeadas. [26] Geral -Os métodos para incorporar metadados em modelos tópicos incluem Dirichlet-multinomial regression mod- els25 e modelos tópicos supervisionados. [7]

Outros tipos de dados. Na LDA, os dados top- ics são distribuídos por palavras e esta distribuição discreta gera observações (palavras em documentos). Um advan- tage do LDA é que estas escolhas para o parâmetro tópico e a distribuição geradora de dados podem ser adaptadas a outros tipos de observações com apenas pequenas mudanças nos algoritmos de inferência correspondentes. Como uma classe de modelos, o LDA pode ser pensado como um *modelo* de *associação mista* de dados agrupados, em vez de associar cada grupo de observações (documento) a um componente (tópico), cada grupo exibe múltiplos componentes em diferentes proporções. Modelos semelhantes ao LDA foram adaptados a muitos tipos de dados, incluindo dados sur- vey, preferências de usuários, áudio e música, código de computador, registros de rede e redes sociais. Descrevemos duas áreas em que o mod- els de associação mista foi particularmente bem sucedido.

Na genética populacional, o mesmo modelo probabilístico foi inventado independentemente para encontrar populações ancestrais (por exemplo, originárias da África, Europa, Oriente Médio, entre outros) na ancestralidade genética de uma amostra de indivíduos.[27] A idéia é que o genótipo de cada índio- vidual descende de uma ou mais populações ancestrais. Usando um modelo muito semelhante ao LDA, os biólogos podem tanto caracterizar os padrões genéticos dessas populações (os "tópicos") quanto identificar como cada indivíduo os expressa (as "proporções dos tópicos"). Este modelo é poderoso porque os padrões genéticos nas populações ancestrais podem ser hipotéticos, mesmo quando os "puros" mesmos ples deles não estão disponíveis.

LDA tem sido amplamente utilizada e adaptada na visão por computador, onde o

algoritmos de inferência são aplicados a imagens naturais ao serviço da recuperação, classificação e organização de imagens. Os pesquisadores de visão por computador fizeram uma analogia direta das imagens aos documentos. Na análise de documentos, assumimos que os documentos exibem tópicos de múltiplas pontas e a coleção de documentos exibe o mesmo conjunto de tópicos. Na análise de imagens, assumimos que cada imagem exibe uma combinação de padrões visuais e que os mesmos padrões visuais se repetem ao longo de uma coleção de imagens. (Em uma etapa de pré-processamento, as imagens são analisadas para formar coleções de "palavras visuais"). O modelo tópico para visão por computador tem sido usado para classificar imagens,[16] conectar imagens e legendas,[4] construir hierarquias de imagens,[2,23,31] e outras aplicações.

direções futuras

A modelagem tópica é um campo emergente no aprendizado de máquinas, e há muitas novas e excitantes direções para a pesquisa.

avaliação e verificação do modelo. Há uma desconexão entre a forma como os modelos temáticos são avaliados e porque esperamos que os modelos temáticos sejam úteis. Tipicamente, os modelos temáticos são avaliados da seguinte forma. Primeiro, apresente um subconjunto do seu corpus como o conjunto de teste. Depois, encaixar uma variedade de modelos tópicos no restante do corpus e aproximar uma medida de ajuste do modelo (por exemplo, probabilidade) para cada modelo treinado no conjunto de teste. Por fim, escolha o modelo que melhor se adapte ao seu desempenho.

Mas modelos temáticos são freqüentemente usados para organizar, resumir e ajudar os usuários a explorar grandes corpora, e não há razão técnica para supor que a precisão corresponde a uma melhor organização ou a uma interpretação mais fácil. Uma direção aberta para a modelagem de tópicos é desenvolver métodos de avaliação que combinem com a forma como os algoritmos são usados. Como podemos comparar modelos tópicos com base na sua capacidade de interpretação?

Este é o problema *de verificação do modelo.* Quando confrontado com um novo corpus e uma nova tarefa, qual modelo temático devo usar? Como posso decidir quais das muitas suposições de modelagem são importantes para meus objetivos? Como devo me mover entre os muitos tipos de modelos temáticos que foram desenvolvidos? Estas questões têm recebido alguma atenção dos estatísticos,[9,30] mas têm sido menos escrutinadas em relação à escala.

de problemas que o aprendizado de máquinas enfrenta. Novas respostas computacionais a estas perguntas seriam uma contribuição significativa para a modelagem de tópicos.

visualização e interfaces de usuário. Outra direção futura promissora para a modelagem de tópicos é desenvolver novos métodos de interação e visualização de tópicos e corpora. Modelos temáticos pró-vídeo nova estrutura exploratória em grandes coleções - como podemos explorar melhor essa estrutura para ajudar na descoberta e exploração?

Um problema é como exibir os tópicos. Normalmente, exibimos os tópicos listando as palavras mais freqüentes de cada um (ver Figura 2), mas novas maneiras de rotular os tópicos - seja escolhendo palavras diferentes ou exibindo as palavras escolhidas de forma diferente - podem ser mais eficazes. Um outro problema é a melhor maneira de exibir um documento com um modelo de tópico. No nível do documento, os modelos de tópicos fornecem informações potencialmente úteis sobre a estrutura do documento. Combinada com etiquetas de tópicos eficazes, esta estrutura poderia ajudar os leitores a identificar as partes mais interessantes do documento. Além disso, as proporções temáticas ocultas conectam implicitamente cada documento aos outros documentos (considerando uma medida de distância entre as proporções temáticas). Como podemos exibir melhor estas conexões? O que é uma interface eficaz para todo o corpus e sua estrutura temática inferida?

Estas são questões de interface com o usuário, e são essenciais para a modelagem de tópicos. Os algoritmos de modelagem temática mostram muitas promessas para a descoberta de uma estrutura temática de média ing ingência em grandes leções de documentos. Mas tornar esta estrutura útil requer atenção cuidadosa à visualização de informações e às interfaces de usuário correspondentes.

Modelos temáticos para a descoberta de dados. Os modelos temáticos foram desenvolvidos com aplicações de engenharia de informação em mente. Como modelo estatístico, porém, os modelos temáticos devem ser capazes de nos dizer algo, ou nos ajudar a formar uma hipótese, sobre os dados. O que podemos *aprender* sobre a linguagem (e outros dados) com base no modelo temático posterior? Alguns trabalhos nesta área têm aparecido na ciência política,[19] biblio- metrics,[17] e psicologia. [32] Este tipo de pesquisa adapta modelos temáticos para mea-certeza de uma variável externa de interesse, uma tarefa difícil de aprendizagem não supervisionada que deve ser cuidadosamente validada.

Em geral, este problema é melhor abordado pela equipe de cientistas da computação com outros estudiosos para usar modelos temáticos para ajudar a explorar, visualizar e desenhar hipóteses a partir de seus dados. Além das aplicações científicas, tais como genética e neurociência, pode-se imaginar modelos temáticos a serviço da história, sociologia, lingüística, ciência política, estudos jurídicos, literatura comparativa e outros campos, onde os textos são um objeto principal de estudo. Trabalhando com estudiosos de diversas áreas, podemos começar a desenvolver uma nova metodologia computacional interdisciplinar para trabalhar e desenhar conclusões a partir de arquivos de textos.

Sumário

Pesquisamos *modelos temáticos probabilísticos*, um conjunto de algoritmos que fornecem uma solução estatística para o problema de gerenciamento de grandes arquivos de documentos. Com os recentes avanços científicos em apoio à aprendizagem não supervisionada de máquinas - componentes flexíveis para modelagem, algorithms escaláveis para inferência posterior e maior acesso a grandes conjuntos de dados - os modelos temáticos prometem ser um componente importante para resumir e compreender nosso crescente arquivo digitalizado de informações.

Referências

1. asuncion, a., welling, m., smyth, P., teh, y. sobre suavização e inferência para modelos tópicos. in *Incerteza na Inteligência Artificial* (2009).
2. bart, e., welling, m., Perona, P. organização não supervisionada de coleções de imagens: taxonomias e mais além. *Trans. Pattern Recognit. Mach. Intell. 33*, 11 (2010) (2301–2315).
3. blei, D., griffiths, t. , Jordan, m. o processo de restaurante chinês aninhado e inferência bayesiana não-paramétrica de hierarquias de tópicos. *J. ACM 57*, 2 (2010), 1-30.
4. blei, D., Jordan, m. modelagem de dados anotados. em *Proceedings of the 26th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* (2003), acm Press, 127-134.
5. blei, D., lafferty, J. Dynamic modelos temáticos. em *International Conference on Machine Learning* (2006), acm, new york, ny, eua, 113-120.
6. blei, D., lafferty, J. um modelo temático correlato da ciência. *Ann. Aplic. Stat., 1*, 1 (2007), 17-35.
7. blei, D., mcauliffe, J. modelos temáticos supervisionados. em *Neural Information Processing Systems* (2007).
8. blei, D., ng, a., Jordan, m. alocação de Dirichlet latente. *J. Mach. Aprenda. Res. 3* (janeiro de 2003), 993-1022.
9. caixa, g. amostragem e inferência de bayes na modelagem científica e robustez. *J. Roy. Stat. Soc. 143*, 4 (1980), 383-430.
10. boyd-graber, J., blei, D. syntactic topic models. in *Sistemas de Processamento de Informações Neurais* (2009).
11. buntine, w. Extensões variáveis para em e multinomial Pca. na *Conferência Européia sobre Aprendizagem de Máquinas* (2002).
12. buntine, w., Jakulin, a. Análise discreta de componentes. *Subespaço, Estrutura Latente e Seleção de Recursos*. c. saunders, m. grobelink, s. gunn, e J. shawe-taylor, eds. springer, 2006.

13. chang, J., blei, D. modelos relacionais hierárquicos para redes de documentos. *Ann. Aplic. Stat. 4*, 1 (2010).
14. Deerwester, s., Dumais, s., landauer, t., Furnas, g., harshman, r. indexação por análise semântica latente. *J. Am. Soc. Inform. Sci. 41*, 6 (1990), 391-407.
15. Doyle, g., elkan, c., contabilizando a explosão em modelos temáticos. em *International Conference on Machine Learning* (2009), acm, 281-288.
16. Fei-Fei, l., Perona, P. a bayesian hierarchical model for learning natural scene categories. in *IEEE Computer Vision and Pattern Recognition* (2005), 524-531.
17. gerrish, s., blei, D. a language-based approach to measuring scholarly impact. in *International Conference on Machine Learning* (2010).
18. griffiths, t., steyvers, m., blei, D., tenenbaum, J. integrando tópicos e sintaxe. *Advances in Neural Information Processing Systems 17*. l. K. saul, y. weiss, e l. bottou, eds. mit Press, cambridge, ma, 2005, 537-544.
19. grimmer, J. a bayesian hierarchical topic model for political texts: measuring expressed agendas expressed expressed in senate press releases. *Polit. Anal. 18*, 1 (2010), 1.
20. hoffman, m., blei, D., bach, F. aprendizagem on-line para alocação de Dirichlet latente. em *Neural Information Processing Systems* (2010).
21. hofmann, t. Probabilistic latent semantic analysis. in *Uncertainty in Artificial Intelligence (UAI)* (1999).
22. Jordan, m., ghahramani, Z., Jaakkola, t., saul, l. introdução aos métodos variacionais para modelos gráficos. *Mach. Aprenda. 37* (1999), 183-233.
23. li, J., wang, c., lim, y., blei, D., Fei-Fei, l., construindo e usando uma hierarquia de imagem semantivisual. em *Computer Vision and Pattern Recognition* (2010).
24. li, w., mccallum, a. Alocação de Pachinko: Dag- modelos de mistura estruturada de correlações de tópicos. em *International Conference on Machine Learning* (2006), 577-584.
25. mimno, D., mccallum, a. modelos temáticos condicionados a características arbitrárias com regressão Dirichlet-multinomial. em *Uncertainty in Artificial Intelligence* (2008).
26. newman, D., chemudugunta, c., smyth, P. modelos estatísticos de entidade-tópica. in *Knowledge Discovery and Data Mining* (2006).
27. Pritchard, J., stephens, m., Donnelly, P. inferência da estrutura da população usando dados de genótipo multilocus. *Genetics 155* (junho de 2000), 945-959.
28. reisinger, J., waters, a., silverthorn, b., mooney, r. spherical topic models. in *International Conference on Machine Learning* (2010).
29. rosen-Zvi, m., griffiths, t., steyvers, m., smith, P., o modelo autor-tópico para autores e documentos. em *Proceedings of the 20th Conference on Uncertainty in Artificial Intelligence* (2004), auai Press, 487-494.
30. Rubin, D. bayesianamente justificável e cálculos de freqüência relevantes para o estatístico aplicado. *Ann. Stat. 12*, 4 (1984), 1151-1172.
31. sivic, J., russell, b., Zisserman, a., Freeman, w., efros, a., descoberta sem supervisão de hierarquias de classes de objetos visuais. em *Conference on Computer Vision and Pattern Recognition* (2008).
32. socher, r., gershman, s., Perotte, a., sederberg, P., blei, D., norman, K. a bayesian analysis of dynamics in free recall. in *Advances in Neural Information Processing Systems 22*. y. bengio, D. schuurmans, J. lafferty, c. K. i. williams, e a. culotta, eds, 2009.
33. steyvers, m., griffiths, t. Modelos temáticos probabilísticos. *Análise Semântica Latente: Um caminho para o significado*. t. landauer, D. mcnamara, s. Dennis, e w. Kintsch, eds. lawrence erlbaum, 2006.
34. os, y., Jordan, m., beal, m., blei, D. processos hierárquicos Dirichlet. *J. Am. Stat. Assoc. 101*, 476 (2006), 1566-1581.
35. wainwright, m., Jordan, m. modelos gráficos, famílias exponenciais, e inferência variacional. *Encontrado. Trends Mach. Aprenda. 1*(1–2) (2008), 1–305.
36. wallach, h. topic modeling: beyond bag of words. in *Proceedings of the 23rd International Conference on Machine Learning* (2006).
37. wang, c., blei, D. Desacoplamento esparsidade e suavidade no discreto processo hierárquico Dirichlet. *Avanços nos Sistemas de Processamento de Informação Neural 22*. y. bengio, D. schuurmans, J. lafferty, c. K. i. williams, e a. culotta, eds. 2009, 1982-1989.
38. wang, c., thiesson, b., meek, c., blei, D. markov modelos temáticos. em *Artificial Intelligence and Statistics* (2009).

David M. Blei (blei@cs.princeton.edu) é professor associado no departamento de informática da Universidade de Princeton, Princeton, n. J.